

Veri Madenciliđi: "Wisconsin Meme Kanseri Veri Seti ile Kümeleme Uygulaması"

Kaggle:

<https://www.kaggle.com/code/yldrmali/main3ff6829c11>

Nuri Buğra Demir – 2022280088

Ali Yıldırım - 2023280134

1. Giriş

Bu çalışmanın amacı, Wisconsin Meme Kanseri teşhis veri seti üzerinde denetimsiz öğrenme yöntemlerinden olan kümeleme algoritmalarını uygulamaktır. Proje kapsamında, veri setindeki doğal grupların (kümelerin), gerçekte "iyi huylu" (Benign) ve "kötü huylu" (Malignant) olarak bilinen teşhislerle ne kadar örtüştüğü incelenmiştir. Çalışma; veri ön işleme, model kurma, model performansını değerlendirme ve sonuçları görselleştirme adımlarını içermektedir. Bu sayede, denetimsiz öğrenme modellerinin etiketlenmemiş tıbbi verilerdeki anlamlı desenleri keşfetme potansiyeli araştırılmıştır.

2. Veri Seti

Çalışmada, makine öğrenmesi alanında sıklıkla kullanılan ve scikit-learn kütüphanesi içerisinde de bulunan **Wisconsin Breast Cancer (Diagnostic)** veri seti kullanılmıştır.

- **Örneklem Sayısı:** 569
- **Özellik Sayısı:** Her bir hücre çekirdeđi ölçümünden elde edilen 30 adet sayısal özellik (örneğin: yarıçap, doku, alan, pürüzsüzlük).
- **Sınıflar:** Veri seti, 212 "kötü huylu" ve 357 "iyi huylu" olmak üzere iki ana sınıftan oluşmaktadır. Bu sınıf etiketleri, modellerin eğitimi sırasında kullanılmamış, yalnızca değerlendirme aşamasında performans ölçümü için referans olarak alınmıştır.

3. Yöntem (Metodoloji)

Proje, aşağıda detaylandırılan adımlar izlenerek gerçekleştirilmiştir.

3.1. Veri Ön İşleme

Kümeleme algoritmalarının doğru ve tarafsız sonuçlar üretebilmesi için veri seti üzerinde iki temel ön işleme adımı uygulanmıştır:

1. **Sınıf Etiketlerinin Ayrılması:** Kümeleme, denetimsiz bir öğrenme yöntemi olduğu için, modelin öğrenme sürecinde "cevapları" görmemesi adına teşhis bilgilerini içeren target sütunu özellik matrisinden ayrılmıştır.

2. **Veri Ölçeklendirme:** Veri setindeki özellikler ("mean area" gibi büyük sayılar ve "mean smoothness" gibi çok küçük sayılar) farklı ölçeklere sahipti. K-Means ve DBSCAN gibi mesafe tabanlı algoritmaların bu ölçek farklarından olumsuz etkilenmesini önlemek amacıyla, tüm özellikler StandardScaler kullanılarak standartlaştırılmıştır. Bu işlem, her özelliğin ortalamasını 0 ve standart sapmasını 1'e getirerek hepsinin model için eşit derecede önemli olmasını sağlamıştır.

3.2. Kümeleme Algoritmaları

Ödev kapsamında iki farklı mantıkla çalışan kümeleme algoritması uygulanmıştır:

- **K-Means:** Merkez (centroid) tabanlı bir algoritmadır. Önceden belirlenen 'K' sayısı kadar küme merkezi bularak her bir veri noktasını kendisine en yakın merkeze atar.
- **DBSCAN:** Yoğunluk (density) tabanlı bir algoritmadır. Birbirine yakın noktalardan oluşan yoğun bölgeleri küme olarak tanımlar ve seyrek, tek başına kalmış noktaları "gürültü" (noise) olarak etiketler. eps (komşuluk yarıçapı) ve min_samples (minimum komşu sayısı) parametrelerine göre çalışır.

4. Bulgular ve Analiz

4.1. Optimal Küme Sayısının Belirlenmesi (K-Means için)

K-Means algoritması için en uygun 'K' değerini belirlemek amacıyla iki farklı yöntem kullanılmıştır:

- **Elbow (Dirsek) Yöntemi:** 1'den 10'a kadar olan K değerleri için Küme İçi Hata Kareleri Toplamı (WCSS) hesaplanmış ve grafiğe dökülmüştür. Grafikteki en belirgin "dirsek" noktasının **K=2** olduğu gözlemlenmiştir.
- **Silhouette Skoru:** Farklı K değerleri için kümelerin ne kadar iyi ayrıştığını ölçen Silhouette skorları hesaplanmıştır. En yüksek skor (yaklaşık 0.34) **K=2** değerinde elde edilmiştir. Her iki yöntemin de aynı sonucu işaret etmesi, K=2 seçiminin doğruluğunu güçlendirmiştir.

4.2. Model Sonuçları

- **K-Means Sonuçları:**
 - K=2 parametresi ile kurulan model, gerçek etiketlerle karşılaştırıldığında **%91.21'lik bir doğruluk** oranına ulaşmıştır.
 - Verinin 30 boyutu PCA ile 2 boyuta indirgenerek görselleştirildiğinde, K-Means'in bulduğu iki kümenin, gerçek "iyi huylu" ve "kötü huylu" sınıflarının dağılımıyla neredeyse birebir örtüştüğü görülmüştür.
- **DBSCAN Sonuçları:**

- DBSCAN için en uygun eps parametresi, NearestNeighbors grafiğiyle yaklaşık **4.5** olarak belirlenmiştir.
- Farklı eps değerleri (1.0, 4.5, 8.0) ile yapılan denemelerde, algoritmanın iki sınıfı ayırt etmede başarısız olduğu görülmüştür. Optimal eps değeriyle bile, model veri setini tek bir büyük küme olarak tanımlamış ve sadece 32 noktayı gürültü olarak etiketlemiştir.
- Bu başarısızlık, **Adjusted Rand Skoru (0.0260)** ve **Homogeneity Skoru (0.0091)** gibi düşük metriklerle de doğrulanmıştır.


5. Sonuç ve Değerlendirme



Bu çalışma, bir veri setine uygun kümeleme algoritmasını seçmenin, verinin kendi iç yapısına ne kadar bağlı olduğunu açıkça göstermiştir.

K-Means, merkezleri belirgin olan küresel (globular) kümeleri ayırmada başarılı bir performans sergilemiştir. **DBSCAN** ise aynı veri setinde başarısız olmuştur, çünkü "iyi huylu" ve "kötü huylu" kümeleri birbirine çok yakın konumlanmış ve aralarında DBSCAN'ın aradığı belirgin bir düşük yoğunluklu bölge bulunmamaktadır. Bu nedenle DBSCAN, bu iki grubu tek bir yoğun bölge olarak algılamıştır.


Sonuç olarak, denetimsiz öğrenme modellerinin, etiket bilgisi olmadan dahi tıbbi verilerde anlamlı desenler bulabileceği gösterilmiştir. Ancak en doğru sonuca ulaşmak için, veri yapısına en uygun algoritmanın dikkatli bir analiz süreciyle seçilmesi gerektiği kanıtlanmıştır.

Grafikler





Gerçek Sınıfların PCA Üzerindeki Dağılımı



DBSCAN için Optimal EPS Değerini Bulma (NearestNeighbors Grafiği)

